

**IMPLEMENTASI SISTEM REKOMENDASI TEKS PADA JUDUL FILM
ANIME DENGAN METODE BIDIRECTIONAL ENCODER
REPRESENTATIONS FROM TRANSFORMERS**



Disusun oleh :

**MUHAMMAD RIZAL
123170036**

**PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNIK INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" YOGYAKARTA
2022**

DAFTAR ISI

DAFTAR ISI	ii
BAB I Pendahuluan.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah.....	3
1.3 Batasan Masalah	4
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	4
1.6 Tahapan Penelitian	4
1.6.1 Rencana dan Tahapan Penelitian	4
1.6.2 Metode Pengembangan Sistem	5
1.6.3 Pengujian Sistem.....	6
1.6.4 Pengujian Penelitian.....	6
1.7 Sistematika Penulisan	6
BAB II Tinjauan Pustaka.....	8
2.1 Anime	8
2.2 Sistem Rekomendasi.....	8
2.2.1 Content Based Filtering	8
2.2.2 Collaborative Filtering	9
2.2.3 Hybrid Filtering	11
2.3 Deep Learning.....	11
2.4 Attention Mechanism.....	14
2.5 Transformers.....	12
2.7 Bidirectional Encoder Representations from Transformers.....	17
2.8 Pre training	19
2.8.1 Masked Language Model	19
2.8.1 Next Sentence Prediction.....	19
2.9 Fine Tuning	20
2.10 Normalized Discounted Cumulative Gain	20
2.10 Root Mean Square Error	21
2.11 Studi Pustaka (<i>State of the Art</i>).....	21
BAB III Metodologi Penelitian	25
3.1 Metodologi Penelitian.....	25
3.2 Studi Literatur.....	26
3.3 Pengumpulan Data.....	26
3.4 Pre-processing	26
3.4.1 Case Folding	27
3.4.2 Remove Punctuation.....	27
3.4.3 Remove Number	27
3.4.4 Stopword Removal	27
3.4.5 Tokenizing	27
3.4.6 Stemming.....	27
3.5 Pembuatan Model.....	27
3.5.1 BERT.....	27
3.6 Pengujian Sistem	27
3.7 Metodologi Pengembangan Sistem	27
3.7.1 Analisis Kebutuhan Sistem.....	27
3.7.2 Kebutuhan Fungsional	27
3.7.3 Kebutuhan Non-Fungsional.....	27
3.7.4 Proses Desain.....	27
3.7.5 Perancangan Sistem.....	27
3.7.8 Perancangan Pengujian.....	27
Daftar Pustaka	27
Lampiran	30

BAB I Pendahuluan

1.1 Latar Belakang

Berkembangnya variasi atas kebutuhan hidup manusia di masa sekarang seakan terus berkembang seiring dengan pertumbuhan teknologi informasi serta telekomunikasi. Termasuk bentuk hiburan yang merupakan salah satu bentuk kebutuhan yang tak lepas dari kehidupan manusia, salah satu bentuk dari hiburan tersebut adalah film (Billah, M et al., 2021). Film yang merupakan kombinasi dari audio serta visual juga terdiri dari berbagai jenis seperti Movie, TV, Dokumentasi dan sebagainya. Animasi merupakan salah satu bentuk bagaimana film ditampilkan yang merupakan kumpulan dari frame yang digambar menggunakan tangan yang kemudian diolah komputer menjadi animasi, animasi atau anime merupakan salah satu teknologi perfilman yang telah berkembang lama di Jepang (Soni, B et al., 2021). Industri anime pada masa sekarang berkembang secara terus menerus dari tahun ke tahun meskipun sempat terjadi penurunan, berdasarkan Anime Report 2020 yang dibuat oleh Asosiasi Animasi Jepang ukuran pasar selama sepuluh tahun terakhir terus berkembang dengan penjualan sebesar 2,51 triliun yen.

Penelitian yang menerapkan sistem rekomendasi menggunakan metode BERT telah diteliti oleh Jeong, C et al., 2020 menerapkan *context-aware recommendation* menggunakan metode BERT dan GCN (*Graph Convolutional Network*), penelitian tersebut menggunakan dataset baru bernama *FullTextPeerRead* yang berisikan konteks kalimat ke referensi sitasi dan metadata *paper* yang menunjukkan hasil yang cukup baik dibandingkan dengan metode yang lain dengan menggunakan beberapa evaluasi yaitu MAP sebesar 0.6189, MPR sebesar 0.6036, evaluasi menggunakan *recall* secara rata – rata sebesar 0.76718, penelitian tersebut memberikan hasil bahwa pengaruh dari kalimat konteks memberikan peningkatan terhadap performa model tetapi pengaruhnya akan berkurang jika sudah mencapai batasan tertentu. Penelitian lainnya oleh Wang, T., & Fu, Y. (2020) yang menerapkan BERT pada *collaborative item-based* penelitian ini menggunakan dataset *e-commerce* membuktikan bahwa metode BERT berhasil melampaui metode BiLSTM dengan hasil precision dengan rata - rata sebesar 0.317, *recall* sebesar 0.791 dan *NDCG* sebesar 0.669. Penelitian tersebut menunjukkan bahwa menyebarkan token pada konteks *e-commerce* berhasil meningkatkan performa model BERT.

Beberapa penelitian sebelumnya yang pernah meneliti sistem rekomendasi anime yang menggunakan *side information* dan informasi user yaitu Nurshadieq & Wibowo., 2020 menerapkan *collaborative filtering* menggunakan LSTM yang bertujuan mengatasi cold-start yang menghasilkan RMSE sebesar 1.4475 yang menunjukkan penelitian tersebut telah lebih baik dibandingkan metode populer seperti SVD dan KNN, penelitian ini membuktikan bahwa dengan mengekstraksi informasi berbasis teks akan mampu memberikan peningkatan performa. Penelitian lainnya juga dicoba oleh Billah, M et al., 2021 yang menerapkan sistem rekomendasi anime berbasis *collaborative filtering* menggunakan PCA dan K-Means yang menghasilkan

kompleksitas waktu sebesar 2,999602 serta menghasilkan nilai akurasi MMR (Mean Reciprocal Rank) sebesar 0.5619. Pada penelitian selanjutnya yang diterapkan oleh Vie, J. J. et al., 2017 yang menerapkan metode baru yang mereka beri nama BALSE (Blended Alternate Least Squares with Explanation) yang merupakan kombinasi dari beberapa metode, pada penelitian tersebut mereka melakukan ekstraksi fitur pada poster anime dan manga dalam merekomendasikan anime. Komponen dari BALSE adalah Illustration2Vec, ALS (Alternate Least Squares), LASSO (Least Absolute Shrinkage and Selection Operator) serta *Steins gate* yang merupakan metode untuk mengkombinasikan hasil dari dua metode ALS dan LASSO. Dari penelitian tersebut dihasilkan nilai RMSE sebesar 1.4954 ± 0.004 menghasilkan kesimpulan bahwa prediksi BALSE lebih baik dibandingkan ALS.

Penelitian yang berkaitan dengan sistem rekomendasi juga telah diterapkan oleh peneliti lain pada rekomendasi movie menggunakan metode LSTM dan CNN oleh Wentao et al (2020) yang menghasilkan MSE sebesar 0,876 dan MAE 0,751. Penelitian yang dilakukan oleh Haili et al., 2020 juga sama menggunakan metode LSTM-CNN dengan menggunakan dataset movieLens menerapkan personalisasi movie rekomendasi yang menghasilkan MAE sebesar 0,7224 dan MSE 0,691739 dari penelitian tersebut menghasilkan nilai yang lebih baik dibandingkan dengan hanya menggunakan metode CNN. Pada penelitian lainnya yang diteliti oleh Lund, J et al., 2018 meneliti Rekomendasi Movie menggunakan Deep Learning dengan metode autoencoder menghasilkan MAE dan RMSE sebesar 0.15 dan 0.35 selain melakukan menggunakan teknik evaluasi tersebut, penelitian tersebut juga menggunakan evaluasi dengan pengguna langsung dengan jumlah 100 orang partisipan menghasilkan survey sebesar 71.67% partisipan lebih memilih menggunakan hasil penelitian tersebut. Kemudian ada juga penelitian yang dilakukan oleh Soni, B et al., 2021 menerapkan sistem rekomendasi anime *hybrid recommendation filtering* yang menggunakan algoritma autoencoder dan clustering spectral yang menggunakan dataset *MyAnimeList* yang menghasilkan RMSE sebesar 0.591 dan 0.349,

BERT merupakan metode yang pada dasarnya adalah tumpukan dari metode *transformer*, sedangkan *transformer* merupakan metode yang dasarnya adalah *attention mechanism* (Devlin, J., et al 2019), penelitian yang menerapkan metode *attention* adalah penelitian Wu, F et al., 2020 yang menggunakan dataset *news recommendation* yang menerapkan metode *attention* yang membuktikan bahwa metode tersebut akan menghasilkan performa yang lebih baik jika dikombinasikan dengan metode *deep learning* lainnya seperti LSTM atau CNN. Salah satu *state-of-art* yang menerapkan *attention* adalah SASRec (*Self-Attentive Sequential Recommendation*) yang diteliti oleh Kang, W. C., & McAuley, J., 2018. Penelitian tersebut menggunakan berbagai dataset berbasis teks yaitu dataset Amazon, MovieLens, dan Steam dari evaluasi ketiga dataset penelitian tersebut berhasil memberikan performa yang lebih baik dibanding metode lain dengan berhasil melakukan peningkatan rata - rata sebesar 6.9% Hit Rate dan NDCG mencapai 9.6% , dengan menggunakan *attention* berhasil menangani *long sequence*.

Sistem Rekomendasi hadir untuk mempermudah dalam pemilihan judul anime yang sesuai. Sistem rekomendasi sendiri umumnya memiliki tiga teknik yaitu

collaborative filtering, *content-based filtering*, dan *hybrid filtering*. Pada penerapannya teknik *collaborative filtering* menggunakan data user lain dalam menerapkan sistem rekomendasinya yang berakibat pada permasalahan cold-start kemudian untuk *content-based filtering* menggunakan data *meta* dari item itu sendiri yaitu menggunakan kemiripan antar satu konten dengan yang lainnya pada penerapannya teknik ini juga memiliki kelemahan salah satunya adalah membutuhkan rating yang cukup sebelum sistem rekomendasi dapat memberikan hasil rekomendasi akurat yang sesuai preferensi user tersebut, yang kemungkinan jika hanya terdapat rating ketika user tersebut baru terdaftar di dalam sistem maka sistem belum bisa memberikan hasil rekomendasi yang sesuai (Lops, P et al., 2011) berdasarkan dari salah satu kelemahan tersebut hadirilah teknik *hybrid filtering* yang bertujuan untuk mengurangi kelemahan dari kedua teknik tersebut.

Penelitian ini akan menerapkan teknik *hybrid filtering* dengan kombinasi antara *content-based filtering* dan *collaborative filtering* dengan menggunakan *hybrid filtering* kelemahan pada salah satu tipe sistem rekomendasi akan teratasi. Salah satunya *Cold-start* bisa diatasi dengan penggunaan *content-based filtering* (Wang, H et al., 2020). Penelitian ini juga akan menambah eksplorasi penelitian *deep learning*, dengan menggunakan *deep learning* model rekomendasi bisa merepresentasikan relasi antar user dan item dengan mempelajari pada *deep-level* jaringan struktur non-linear (Wang, W et al., 2020). Pada penelitian ini akan menggunakan metode BERT4REC. Alasan menggunakan metode BERT adalah metode tersebut merupakan metode state-of-art yang terbaru yang diteliti oleh Fei Sun et al., (2018). BERT merupakan model yang sudah *dipre-trained* sehingga penggunaannya akan lebih mudah, meskipun begitu BERT masih bisa di *fine-tuned* sesuai *problem* yang ingin diselesaikan, BERT juga merupakan metode yang mampu membaca teks dari kanan ke kiri (*bidirectional*) sehingga mampu membaca keseluruhan konteks, hal yang membedakannya dengan BiLSTM adalah kemampuan memprosesnya lebih cepat secara parallel (Devlin, J., et al., 2019).

Data yang akan digunakan bersumber dari dataset yang ada yang berasal dari situs *kaggle* selain itu dataset yang akan digunakan tidak hanya satu tipe dataset. Dengan diterapkan penelitian ini diharapkan dapat menghasilkan sistem rekomendasi yang mampu menghasilkan rekomendasi anime yang lebih baik dari sistem yang telah ada. Sistem yang mampu merekomendasikan sesuai prefensi dari user tersebut serta mampu memperluas pengalaman user dalam menggunakan sistem rekomendasi ini.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan sebelumnya maka didapatkan rumusan masalah sebagai berikut :

1. Menerapkan sistem rekomendasi pada text judul anime menggunakan metode Bidirectional Encoder Representations From Transformers
2. Bagaimana hasil metode sistem rekomendasi yang diterapkan yaitu BERT

1.3 Batasan Masalah

Penelitian ini memiliki batasan dalam penyelesaiannya, sebagai berikut :

1. Menggunakan data penelitian yang bersumber dari *myanimelist* (kaggle).
2. Data penelitian berbahasa inggris.
3. Data penelitian ini berformat .csv
4. Sistem rekomendasi pada penelitian ini menggunakan data masukan yang terbatas pada judul anime, genre, score, studio, favorites, members, sinopsis dan riwayat user
5. Pada penelitian data keluaran yang dihasilkan hanya judul anime, genre, score, studio dan sinopsis.
6. Data anime yang akan digunakan pada penelitian ini merupakan anime yang tayang sejak tahun 1979 hingga 2018.

1.4 Tujuan Penelitian

Penelitian ini memiliki tujuan, sebagai berikut :

1. Mengetahui tingkat akurasi penerapan metode BERT terhadap hasil rekomendasi yang diberikan
2. Mengetahui cara kerja pada penerapan metode BERT pada sistem rekomendasi

1.5 Manfaat Penelitian

Manfaat dari penelitian ini adalah berusaha untuk memberikan hasil rekomendasi terbaik kepada orang - orang penonton aktif film anime maupun orang - orang yang baru mengenal film anime, selain itu penelitian juga bertujuan untuk meningkatkan eksplorasi metode deep learning khususnya pada penerapan metode BERT pada sistem rekomendasi.

1.6 Tahapan Penelitian

Tahapan penelitian yang diterapkan pada penelitian ini adalah sebagai berikut :

1.6.1 Rencana dan Tahapan Penelitian

a. Studi Literatur

Pada penelitian ini permasalahan dan penyelesaian yang diselesaikan dihimpun dari berbagai referensi sumber literatur yang relevan dan sesuai dengan penelitian ini.

b. Pengumpulan dan Pengolahan Data

Pada tahapan ini data dikumpulkan berasal dari situs *kaggle* yang kemudian diolah dan dipilah yang mana saja yang akan dijadikan data penelitian.

c. Analisis Sistem

Analisis sistem ini dilakukan untuk menganalisa berbagai keperluan dalam proses perancangan sistem sehingga memudahkan dalam proses selanjutnya.

d. Perancangan Sistem

Pada tahapan ini merupakan penerapan dari analisis sistem sebelumnya yaitu menerapkan pemodelan terhadap sistem yang akan dibuat pada penelitian ini.

e. Implementasi Perangkat Lunak

Tahapan ini merupakan tahapan mengimplementasikan sistem yang sebelumnya sudah dirancang.

f. Pengujian dan Analisis

Pada tahapan ini dilakukan pengujian terhadap sistem yang telah diimplemtasikan sebelumnya, yang kemudian akan dilakukan analisis terhadap hasil pengujian yang telah dilakukan.

g. Kesimpulan dan Saran

Pada tahapan ini penelitian akan diberikan kesimpulan dari hasil pengujian yang telah dilakukan dan kemudian akan disertakan saran yang selanjutnya dapat dikembangkan untuk penelitian selanjutnya sehingga mendapatkan hasil penelitian yang lebih baik.

1.6.2 Metode Pengembangan Sistem

Metode pengembangan sistem yang akan digunakan pada penelitian ini adalah *prototyping*. *Prototyping* atau *prototype* digunakan dengan alasan karena dengan menggunakan metode ini kedekatan antara perancang dan pengguna. Dengan proses yang dilakukan secara terstruktur pada setiap tahapan pembuatannya membuat sistem lebih cepat dan lebih hemat dibandingkan metode pengembangan sistem lainnya. Tahapan pada proses *prototyping* (Pressman, 2015) adalah sebagai berikut :

1. *Communication*

Pada tahapan awal pengembangan sistem melakukan komunikasi dan kolaborasi antara pengguna atau pemangku kepentingan dengan maksud memahami tujuan dan kebutuhan sistem sehingga bisa mempermudah dalam menentukan fitur dan fungsi sistem yang akan dibangun.

2. *Planning*

Pada tahapan ini dilakukan perencanaan yang berfungsi untuk mempermudah pengembang saat proses pembuatan sistem. Tahap planning mendeskripsikan tugas teknis, resiko yang mungkin akan terjadi, kebutuhan sumber daya, hasil produk, dan jadwal pengerjaan sistem.

3. *Model*

Pada tahapan ini pengembang membuat model dari sistem yang akan dibuat sehingga pengembang dapat memahami kebutuhan sistem dan desain yang sesuai untuk menunjang kebutuhan tersebut.

4. *Construction*

Pada tahap construction, pengembang memulai pembuatan sistem tahap sebelumnya, selain itu tahap ini juga melakukan pengujian atau testing untuk menemukan kesalahan pada pembuatan sistem.

5. *Deployment*

Pada tahap ini sistem yang telah dibuat dikirimkan kepada pengguna baik semua fitur selesai maupun sebagian untuk mendapatkan evaluasi produk dan memberikan feed back berdasarkan evaluasi.

1.6.3 Pengujian Sistem

Pengujian sistem yang akan digunakan pada penelitian ini adalah metode black box testing, yaitu metode yang pengujian sistem yang menekankan fungsionalitas tanpa mengetahui coding dari sistem tersebut. Black box testing bertujuan untuk mengukur kinerja dari sistem yang telah dibangun.

1.6.4 Pengujian Penelitian

Pengujian penelitian biasa digunakan pada penelitian rekomendasi sistem adalah NDCG (Normalized Discounted Cumulative Gain) dan RMSE (Root Mean Square Error). Kedua metode tersebut merupakan metode yang paling sering digunakan pada penerapan sistem rekomendasi. NDCG mampu memperhitungkan relevansi dan posisi dari sebuah item sehingga mampu memperhitungkan keakuratan lebih tepat (Wang, Y., et al., 2013), sedangkan RMSE merupakan metode yang mampu memperhitungkan seberapa jauh nilai prediksi dengan nilai kebenarannya sehingga peneliti mampu mempertimbangkan kinerja model yang dibuat pada model yang dibuat sehingga bisa diidentifikasi yang kemudian bisa dilakukan perbaikan pada model tersebut sehingga bisa membantu meningkatkan kinerja model tersebut.

1.7 Sistematika Penulisan

Sistematika penulisan yang digunakan dalam menyusun laporan penelitian ini adalah sebagai berikut:

Bab I Pendahuluan

Pada bagian ini membahas tentang latar belakang masalah, rumusan masalah, tujuan penelitian, manfaat penelitian, batasan masalah, metodologi penelitian, dan sistematika penulisan.

Bab II Tinjauan Literatur

Tinjauan literatur memuat tentang dasar teori yang sudah ada sebagai bahan referensi terkini dan pondasi untuk memperkuat argumentasi dalam penelitian ini sekaligus mendasari pemecahan masalah dalam penelitian ini.

Bab III Metodologi Penelitian dan Pengembangan Sistem

Bab ini membahas tentang tahap perancangan kebutuhan, tahap analisis, dan tahap perancangan serta memberikan gambaran garis besar penyusunan program.

Bab IV Hasil, Pengujian dan Pembahasan

Pada bab ini akan menyajikan hasil penelitian berisi hasil implementasi dari perancangan yang telah dibuat pada bab sebelumnya dan berisi pengujian terhadap hasil penelitian beserta pembahasannya

Bab V Kesimpulan dan Saran

Pada bab ini berisi kesimpulan dari hasil penelitian dan saran yang diajukan untuk pengembangan penelitian selanjutnya.

BAB II Tinjauan Pustaka

2.1 Anime

Anime merupakan kartun yang aslinya berasal dari Jepang, selain itu istilah Anime dalam bahasa Inggris adalah *animation* (B. Soni et al., 2021). Anime atau kartun pada dasarnya memiliki definisi yang sama yaitu kumpulan gambar / frame yang disusun sehingga membentuk animasi. Perbedaan yang membuat anime berbeda pada kartun yang sejenis adalah desain dari karakter anime yang memiliki ciri khas tersendiri seperti memiliki mata yang besar. Anime juga memiliki format penayangan yang cukup bervariasi yaitu TV, Movie, ONA, OVA, dan OAD (Billah, M et al., 2021). Selain itu anime juga memiliki banyak kategori tidak hanya genre yang bervariasi terdapat musim tayang, sumber cerita (*manga, original, light novel*), dan studio.

2.2 Sistem Rekomendasi

Sistem rekomendasi merupakan sistem yang bertujuan untuk menghasilkan suatu *item* kepada user sehingga user mampu meningkatkan pengalaman penggunaan terhadap aplikasi yang menggunakan sistem rekomendasi tersebut, sehingga user bisa membuat keputusan terhadap sesuatu hal yang diinginkannya. biasanya sistem rekomendasi menghasilkan item secara spesifik seperti merekomendasikan musik ataupun berita (Ricci, F et al., 2011). Sistem rekomendasi juga bisa dilihat sebagai sistem pencarian ranking dimana query masukannya adalah kumpulan dari user dan konteks data informasi yang berhubungan (Cheng, H. T et al., 2016)

Sistem rekomendasi hadir untuk mengurangi derasnya arus informasi yang hadir di internet dengan adanya sistem rekomendasi user mampu memilih serta menentukan arus informasi yang seperti apa yang sesuai kebutuhan user tersebut. Sistem rekomendasi merupakan sistem yang terpersonalisasi yang ditujukan secara khusus kepada setiap user tergantung dari kebutuhan user itu sendiri sehingga tujuan dari sistem rekomendasi adalah meningkatkan pengalaman ditujukan kepada satu user bukan merepresentasikan suatu grup secara keseluruhan (Burke, R et al., 2011)

Dalam pendekatannya sistem rekomendasi biasanya menggunakan dua pendekatan yaitu *collaborative filtering*, *content based filtering* dan *knowledge based*. Dengan perkembangan informasi saat ini yang lebih kompleks maka hadirlah metode *hybrid filtering* yang mengkombinasikan kedua kemampuan dari metode tersebut sehingga bisa saling menutupi kekurangan satu sama lain.

2.2.1 Content Based Filtering

Content Based Filtering merupakan salah satu pendekatan yang terdapat pada sistem rekomendasi yang lebih berfokus terhadap atribut atau *features* yang terdapat pada *item* yang akan direkomendasikan kepada user. Content based filtering

merupakan metode yang dimana orang - orang yang menyukai sebuah item dengan beberapa atribut di aktifitas sebelumnya yang dimana di masa depan akan memiliki item yang rekomendasi yang mirip dengan item tersebut (Çano, E., & Morisio, M., 2017).

Satu kunci permasalahan dari rekomendasi content-based adalah kualitas dari feature. Item yang direkomendasikan membutuhkan deskripsi atribut yang jelas dan berarti sehingga rekomendasi item tersebut kepada user bisa dilakukan (Burke, R et al., 2011). Teknik *content-based filtering* tidak membutuhkan data *profile* orang lain karena hal tersebut tidak mempengaruhi hasil rekomendasi, selain itu jika data user profile berubah teknik content-based masih mempunyai potensi untuk menyesuaikan hasil rekomendasi dalam waktu yang singkat (Isinkaye, F et al., 2015).

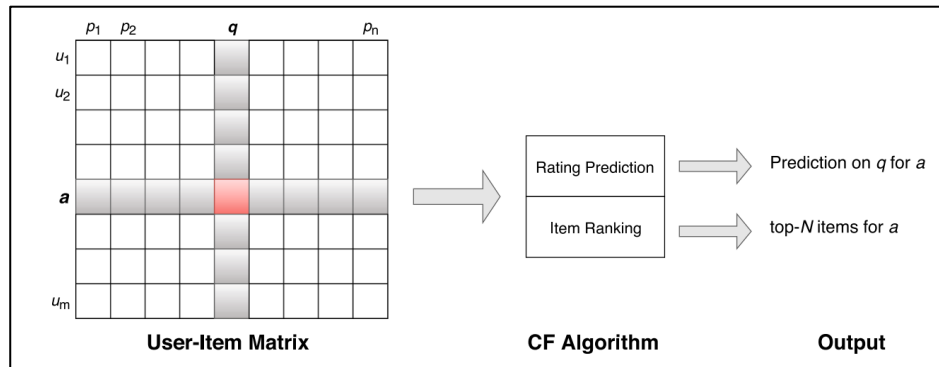
Keuntungan dengan menggunakan teknik content-based yaitu mampu memberikan rekomendasi item baru meskipun user tidak memberikan rating kepada item - item yang dituju oleh user tersebut, jadi meskipun database tidak menyediakan data user preferensi hal itu tidak mempengaruhi tingkat keakurasian sistem rekomendasi (Isinkaye, F et al., 2015). User tidak perlu untuk berbagi preferensi satu sama lain sehingga memastikan keamanan *privacy* user tersebut. *Content-based filtering* juga memberikan rekomendasi yang *transparency* artinya sistem rekomendasi yang diberikan sangat jelas dan masuk akal karena memiliki keterhubungan dengan item yang user sukai dari aktifitas user itu sendiri berbeda dengan *collaborative filtering* yang mengambil kecocokan item berdasarkan data dari user lain yang artinya *item* rekomendasi yang diberikan belum tentu memiliki kesamaan *features* dengan *item* yang sesuai prefensi user tersebut (Ricci, F et al., 2011).

Kekurangan dari menggunakan pendekatan CBF ini adalah Keterbatasan hasil rekomendasi karena terlalu bergantung kepada features yang terdapat pada item preferensi user tersebut sehingga hasil rekomendasi yang diberikan oleh sistem akan terbatas pada konten dengan tema yang sama yang kadang bisa memberikan hasil rekomendasi yang sama tanpa ada hasil rekomendasi yang baru. (Ricci, F et al., 2011). Pada teknik CBF juga sulit mendapatkan *feedback* dari user karena user terbiasa untuk tidak memberikan rating kepada hasil rekomendasi yang diberikan mengakibatkan sulit untuk mengetahui apakah rekomendasi yang diberikan merupakan hasil yang benar atau tidak. (Modallal, S., 2015)

2.2.2 Collaborative Filtering

Collaborative Filtering adalah metode sistem rekomendasi yang menghasilkan hasil rekomendasi secara spesifik yang dilakukan dengan cara melakukan pendekatan berdasarkan kemiripan selera dengan pengguna lain. Collaborative filtering adalah sebuah sistem rekomendasi yang mempunyai cara kerja yang cukup berbeda dengan content-based pada teknik ini prediksi sistem rekomendasi bukan dihasilkan dari deskripsi metadata seperti deskripsi yang terdapat pada movie dan musik, pada teknik pendekatan yang digunakan adalah menggunakan preferensi item oleh user jadi user yang memiliki kemiripan preferensi akan

menghasilkan prediksi sesuai kemiripan preferensi antar user. (Isinkaye, F et al., 2015) Aktor utama dari sistem rekomendasi CF adalah user yang secara aktif mencari hasil rekomendasi dari ranking items atau prediksi rating. Dengan memanfaatkan prefensi sebelumnya sebagai patokan untuk menentukan korelasi antar user, sebuah pendekatan CF mengandalkan prefensi pengguna yang sesuai. (Batmaz, Z et al., 2019) .



Gambar 2.1 Gambaran sederhana Collaborative Filtering (Batmaz, Z et al., 2019)

Umumnya terdapat pada collaborative filtering terdapat dua pendekatan yaitu *memoery-based* dan *model-based*.

A. Memory-based filtering

Memory based filtering dikenal sebagai *neighborhood fltering*, metode collaborative filtering memanfaatkan kombinasi dari *ratings user-items* yang terprediksi melalui basis kedekatan mereka (Aggarwal, C. C., 2016). Terdapat dua pendekatan yang digunakan pada *memory-based filtering* ini yaitu :

1. User-based collaborative filtering

Pada pendekatan *user-based* ini memanfaatkan kemiripan preferensi user yang kemudian memberikan rekomendasi item berdasarkan kemiripan preferensi user. Sebagai contoh misal user A dan User B menyukai item P maka hasil rekomendasi jika user B menyukai item Q berarti ada kemungkinan user A akan menyukai item Q juga.

2. Item-based collaborative filtering

Pada pendekatan *item-based* berfokus pada kemiripan selera item jadi hasil rekomendasi yang diberikan akan berdasarkan kemiripan selera item sebagai contoh misal banyak user yang jika menyukai item A maka menyukai item B maka user yang menyukai item A akan diberikan rekomendasi item B.

B. Model-based filtering


Model-based filtering merupakan teknik collaborative filtering yang menggunakan model machine learning atau teknik data mining. Dengan menggunakan pendekatan ini dibandingkan dengan *memory-based* atau *neighborhood-based systems* pada *model-based* pendekatan yang digunakan adalah dengan menggunakan rating untuk belajar pada model prediksi yang akan diterapkan (Ricci, F et al., 2011). Ide dasar dari model-based adalah memodelkan hubungan antara user-item dengan fitur antara pengguna dan item dalam sistem, seperti preferensi dari user dan kategori dari item. Model ini dilatih dengan menggunakan data yang tersedia yang kemudian digunakan untuk memprediksi rating user untuk item baru.

2.2.3 Hybrid Filtering

Hybrid Filtering yaitu teknik sistem rekomendasi yang menggabungkan atau mengkombinasikan dua atau lebih teknik sistem rekomendasi. Variasi teknik rekomendasi yang telah ada hingga saat ini adalah *content-based*, *collaborative-filtering*, *knowledge-based* dan *demographic technique* dari tiap teknik tersebut masing - masing memiliki kekurangan sehingga untuk menanggulangi kekurangan tersebut adalah dengan menggunakan teknik *hybrid filtering*. Salah satu kelemahan yang paling umum dari teknik *content-based* dan *collaborative filtering* adalah *cold-start* (Burke, 2007) yang dimana kelemahan tersebut adalah singkatnya adalah apa hal yang direkomendasikan kepada user yang memiliki hanya sedikit rating.

2.3 Deep Learning

Deep learning merupakan bidang yang masih sangat digandrungi oleh komunitas *machine learning* dan *data mining*, *deep learning* itu sendiri termasuk cabang dari machine learning (Alfarhood, M., & Cheng, J. 2021). Model dari *deep learning* ini sendiri bisa dilatih dengan *supervised learning* ataupun unsupervised learning. Definisi sederhana dari *deep learning* adalah setiap jaringan syaraf dengan lebih dari dua lapisan (Suyanto et al., 2019). Berikut gambaran dasar dari deep learning :



Gambar 2.2 (a) Arsitektur umum dari jaringan syaraf deep learning, (b) Jaringan syaraf tiruan: Diagram Perhitungan dasar untuk jaringan syaraf. (Selvaraj, S., 2021)

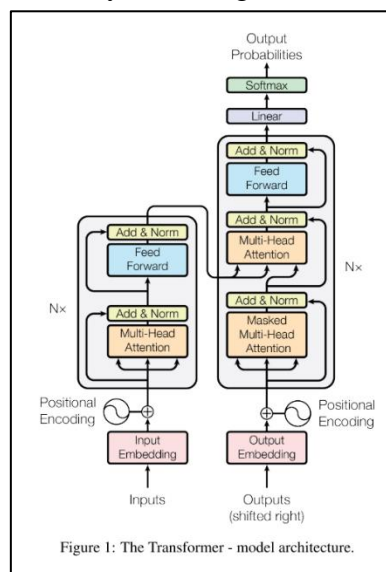
Alasan mengapa *deep learning* cocok digunakan pada bidang sistem rekomendasi menurut Alfarhood, M., & Cheng, J. 2021 adalah

(1) *End to End Differentiable* maksudnya adalah umumnya pada metode tradisional penelitian dilaksanakan pada beberapa tahap dengan menggunakan *deep learning* hal tersebut bisa diperpendek dengan menjadikannya hanya dengan satu tahapan yaitu dengan hanya menggunakan sebuah *neural network*.

(2) Memberikan *inductive bias* yang sesuai kepada tipe data masukan. *Inductive bias* memungkinkan sebuah algoritma pembelajaran untuk memprioritaskan satu solusi dibandingkan yang lain, *inductive bias* mampu memberikan asumsi tentang proses pembuatan data atau kemungkinan ruang solusi (Battaglia, P. W et al., 2018). Karena hal tersebut jika terdapat struktur yang inheren yang dapat dieksploitasi oleh model, maka dengan begitu deep neural networks bisa berguna.

2.4 Transformers

Transformers adalah model arsitektur yang dibuat berdasarkan atas konsep *attention mechanism*. Transformers merupakan model *transduction* pertama yang sepenuhnya menggunakan self-attention untuk mengolah representasi *input* dan *output* tanpa menggunakan *sequence-aligned RNN* ataupun *Convolution* (Vaswani, A., et al., 2017). Transformer merupakan model *state-of-art* pada bidang *Natural Language Processing* yang menggantikan model yang paling umum digunakan pada arsitektur *encoder-decoder* dengan menggunakan *multi-headed self-attention*. Transformer adalah model deep learning yang mana setiap keluaran saling terhubung dengan setiap elemen dan pembobotannya diperhitungkan secara dinamis berdasarkan atas hubungan antar elemennya. Sesuai ilustrasi di bawah Transformers tersusun oleh encoder dan decoder. Dari kedua struktur tersebut secara garis besar Transformers memiliki tiga hal penting yang menyusunnya yaitu *self attention*, *feed-forward neural network* dan *positional encoding*. Berdasarkan arsitektur transformers terdapat beberapa *term* yang penulis jelaskan yaitu sebagai berikut :



Gambar 2.3 Transformers Arsitektur (Vaswani, A., et al 2017)

2.4.1 Positional Encoding

Positional Encoding digunakan untuk menggantikan *reccurence* atau *convolutional* yang bertujuan untuk mendapatkan informasi secara relatif atau jelas mengenai posisi dari tokens yang terdapat pada *sequence* (Vaswani, A., et al 2017). Positional encoding terletak sebelum encoder stacks dan setelah decoder stacks. Postional encoding memiliki ukuran dimensi yang sama dengan embedding sehingga embedding dan positional encoding bisa dijumlahkan dengan embedding. Berikut formula Positional Encoding yang digunakan oleh Vaswani, A et al., 2017

$$PE(pos, 2i) = \sin(pos/10000^{2i/d^{model}}) \dots \dots \dots (2.19)$$

$$PE(pos, 2i+1) = \cos(pos/10000^{2i/d^{model}}) \dots \dots \dots (2.20)$$

Keterangan :

PE : Positional Encoding
 d^{model} : dimensional embedding

Dengan formula diatas setiap input vector dengan indeks ganjil, menggunakan fungsi cos sedangkan item input dengan indeks genap emnggunakan fungsi sin, yang kemudian jumlahkan dengan embedding.

2.4.2 Encoder Stacks

Encoder stack yang berada di posisi kiri dari arsitektur transformer di gambar 2.3 bertujuan untuk memetakan semua masukan *sequences* ke bentuk representasi berkelanjutan *sequences* yang akan digunakan dilanjutkan ke *decoder stacks*. Encode layer tersusun oleh dua sub modules yaitu *multi-head attention* dan *feed forward network* serta terdapat juga *residual connections* di masing - masing sub layer tersebut juga terdapat layer *normalization*. Kenyataannya *encoder stacks* tersusun oleh 6 stack identical layers arsitektur di atas merupakan contoh dari single stack dari transformers (Vaswani, A., et al 2017). Keluaran dari masing - masing sub-layer adalah $LayerNorm(x + SubLayer(x))$, di mana $SubLayer(x)$ merupakan fungsi yang diimplementasikan oleh sublayer itu sendiri. Dalam rangka membantu residual connections, semua sublayer yang ada di model ini termasuk embedding layer menghasilkan keluar dimension d_{model} sebesar 512.

2.4.3 Decoder Stacks

Decoder stacks yang berada di sebelah kanan di arsitektur transformer pada gambar 2.3 bertujuan untuk menerima keluaran dari encoder yang secara berbarengan menghasilkan keluaran yang telah diproses sebelumnya untuk menghasilkan keluaran *sequence*. Decoder stacks memiliki struktur yang mirip dengan encoder stacks, perbedaan yang dimiliki adalah pada decoder memiliki sub-layer tambahan ketiga di atas positional encodieng sebelum output embedding. Pada decoder ini ditambahkan

modifikasi self-attention pada sub-layer untuk mencegah posisi dari memperhatikan ke posisi selanjutnya (Vaswani, A., et al 2017). Sub-layer ini meskipun memiliki kemiripan dengan yang ada di encoder tetapi masing - masing dari layer multi-head attention ini memiliki fungsi yang berbeda - beda.

2.4.4 Multi-head Attention

Multi-head attention merupakan module yang digunakan oleh attention mechanism yang mana menjalankan attention mechanism secara parallel. Pada Transformers ini Multi-head mechanism menggunakan *self-attention*. Multi-head attention memungkinkan model untuk bersama-sama memperhatikan informasi dari representasi sub ruang yang berbeda pada posisi yang berbeda (Vaswani, A., et al 2017). Secara intuitif, multiple-attention memungkinkan untuk memperhatikan ke bagian bagian pada sequence yang berbeda. Berikut formula matematis *multi-head attention* :

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^o \dots\dots\dots (2.21)$$

$$\text{head}_i = \text{Attention}(QW_i^q, KW_i^k, VW_i^v) \dots\dots\dots (2.22)$$

Keterangan :

Q : Query

W : Bobot

K : Key

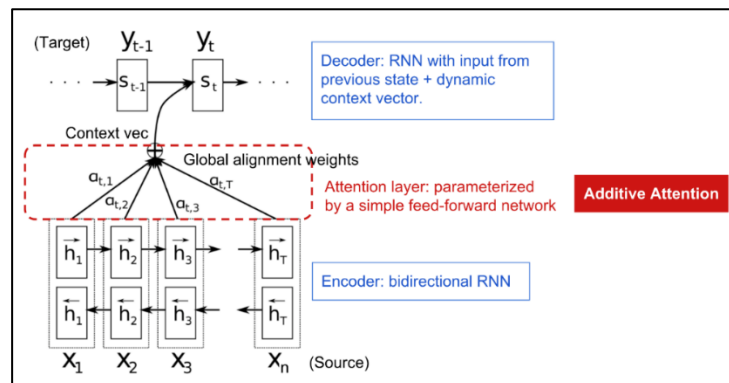
V : Value

2.4.5 Attention Mechanism

Mekanisme Atensi (Attention Mechanism) merupakan teknik yang umumnya dikenal sering digunakan pada bidang *natural language processing* (NLP) yang menggunakan model *Seq2Seq encoder-decoder* umumnya *standard-encoder* melakukan operasi dengan cara mengencoder proses masukan *sequence* dan kemudian mengkompres atau menyederhanakan informasi tersebut menjadi konteks vektor yang mempunyai panjang yang tetap untuk kemudian diteruskan ke *decoder*. Kekurangan dari panjang vektor yang tetap ini mengakibatkan ketidakmampuan sistem dalam mengingat *sequences* yang panjang serta dalam menentukan kepentingan informasi terbaru terlepas dari relevansi yang sebenarnya, dengan menggunakan permasalahan tersebut berhasil diatasi (Katrompas, A., & Metsis, V., 2022).

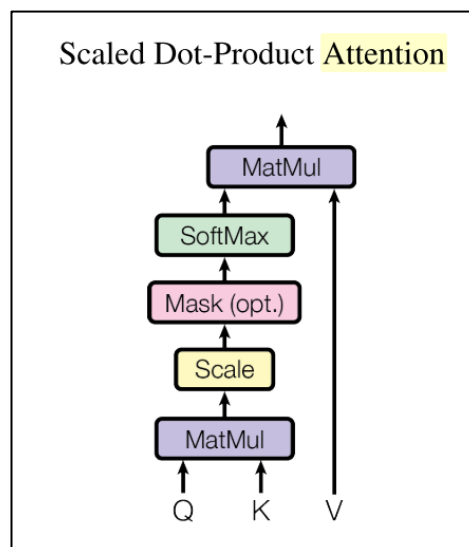
Attention Mechanism merupakan algoritma yang bertujuan untuk membantu model *neural network* meningkatkan performanya dengan cara fokus pada *local feature* yang mempunyai hubungan lebih kuat dibanding yang lainnya pada saat model dilatih. Teknik mekanisme memberikan memberikan kemampuan pada model

untuk fokus pada bagian terpenting pada target dengan pembobotan yang berbeda (Xu, C., et al 2021). Berikut ilustrasi dari attention layer



Gambar 2.4 Attention Layer pada Seq2Seq model (Bahdanau et al., 2015)

Atensi mekanisme memiliki konsep yang pada dasarnya yaitu dengan cara memberikan *weighted access* pada tiap timestep yang bertujuan untuk meningkatkan kemampuan model dalam memproses *sequential data*. *Attention mechanism* telah membuktikan mampu memberikan bobot pada item tertentu sesuai kepentingan item tersebut dan mekanisme perhatian juga berguna untuk membentuk karakteristik pengguna. (Huang, R., et al 2018). Umumnya Attention Mechanism terdiri dari tiga komponen utama yaitu Q (*queries*), K (*keys*) dan V (*values*). Sebuah fungsi attention merupakan fungsi yang memetakan query dan satu set pasangan key dan value yang bertugas sebagai output, dari komponen - komponen tersebut semuanya merupakan vector.



Gambar 2.5 Scaled Dot-Product Attention (Vaswani, A., et al 2017)

Scaled Dot-Product Attention merupakan komponen dari *Multi-head Attention*, *Scaled Dot-Product* merupakan salah satu bentuk fungsi *attention* yang lebih cepat, dan memiliki ruang efisiensi yang lebih luas dalam praktiknya karena pada penerapannya menggunakan matriks multiplication yang telah teroptimisasi (Vaswani, A., et al 2017). Bentuk formula yang digunakan fungsi *attention* adalah sebagai berikut :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

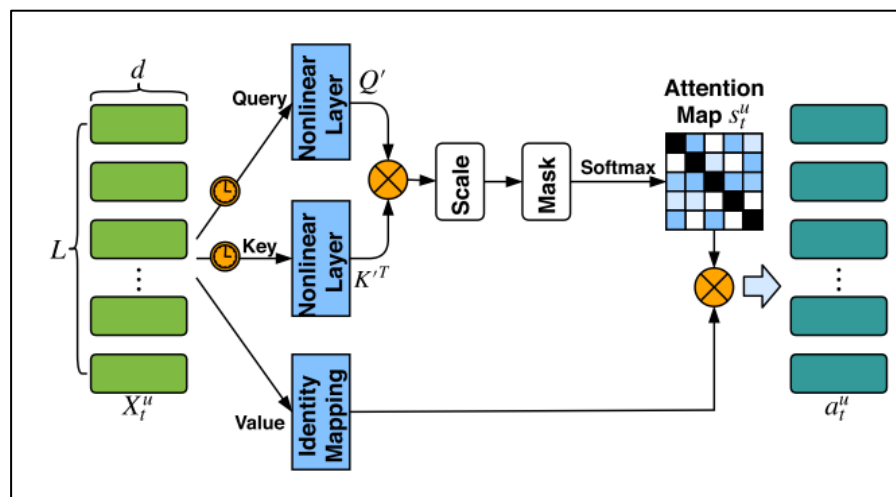
Gambar 2.6 Formula Scaled Dot-Product Attention (Vaswani, A., et al 2017)

Keterangan :

Q : Query
K : Key
V : Value
 d_k : Dimension key

2.4.6 Self Attention

Self-attention merupakan model attention yang juga memiliki sebutan *intra-attention* adalah model yang memungkinkan masukan untuk berinteraksi satu sama lain dengan masukan itu sendiri yang bertujuan untuk mencari siapa yang harus diberikan perhatian lebih. *Self-attention* memiliki kemampuan lebih baik dibanding pendahulunya seperti RNN dan CNN dan bahkan bisa menggantikan model - model tersebut pada bidang sequence learning, kelebihanannya memiliki akurasi yang lebih baik dengan komputasi kompleksitas yang lebih rendah (Zhang, S et al., 2018).



Gambar 2.7 Ilustrasi Modul Self-Attention (Zhang, S et al., 2018).

Tidak seperti *attention* yang pada umumnya mempelajari representasi dengan batasan informasi pada keseluruhan konteks, *self-attention* mampu mempertahankan konteks informasi secara sequential dan melihat hubungan antar elemen yang ada di sequence, terlepas dari panjangnya sequence tersebut. Susunan dari yang menyusun self-attention adalah *scaled dot-product attention*. Masukan yang diterima oleh self-attention tersusun oleh query, key dan value, sedangkan keluaran dari outputnya

adalah jumlah bobot dari value dimana bobot matriks atau penghubung matriks ditentukan oleh query dan key yang sesuai.

Self-attention menerima masukan matriks $X \in R^{T \times D_{in}}$ dengan tersusun dengan sejumlah T token dengan dimensi sebesar D_{in} . Dengan formula self-attention sebagai berikut (Cordonnier, J.-B., et al., 2019) :

$$\text{Self-Attention}(X)_t := \text{softmax}(A_t, :) X W_v \dots \dots \dots (2.23)$$

$$A := X W_q W_k^T X^T \dots \dots \dots (2.24)$$

Keterangan :

X : Matriks input
 W_q : Bobot query
 W_k^T : Bobot key
 W_v : Bobot value

2.4.7 Feed Forward Networks

Feed Forward Networks terdiri dari dua fully connected layer. Implementasi Feed-forward network diterapkan pada masing-masing posisi secara terpisah dan identik. Jumlah dari dimensi di hidden layer feed forward network ini secara umum adalah sekitar empat kali lipat dari token embedding dmodel, jadi terkadang feed forward network disebut dengan expand-and-contract network. Sedangkan transformasi linear diterapkan secara sama di berbagai posisi yang berbeda, transformasi linear menggunakan parameter yang berbeda dari layer satu ke layer lain. Cara lain dalam mendeskripsikan hal ini menganggap dua konvolusi dengan ukuran kernel 1. Dimensi input dan output $d_{model} = 512$ dan inner layer memiliki dimensi sebesar $d_{ff} = 2048$

$$\text{FFN}(x) = \max(0, x W_1 + b_1) W_2 + b_2 \dots \dots \dots (2.25)$$

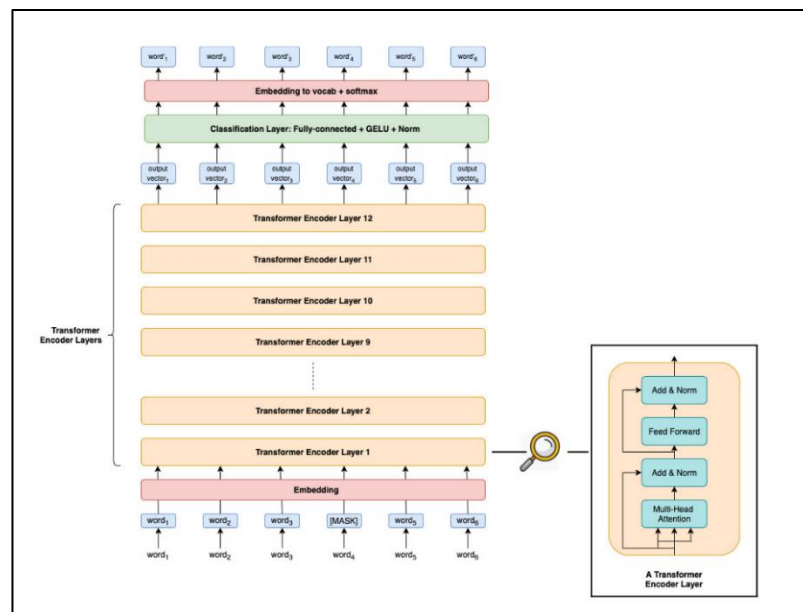
Keterangan :

Max : fungsi ReLu
W : bobot
b : bias

2.5 Bidirectional Encoder Representations from Transformers

BERT atau Bidirectional Encoder Representations from Transformers merupakan algoritma yang bertujuan untuk mempelajari representasi kata melalui dua tahapan tugas. Tugas pertama adalah memprediksi kata - kata yang hilang yang terdapat pada kalimat, berdasarkan sisa - sisa katanya yang terdapat pada kalimat tersebut. Tugas Kedua bertugas untuk menentukan apakah kalimat kedua dari dua kalimat adalah kalimat lanjutan atau apakah itu berasal dari teks yang sama sekali tidak berhubungan. BERT merupakan model algoritma yang dibuat oleh Google. BERT digunakan untuk

membuat model state-of-art pada berbagai tugas. BERT dipublikasikan pada tahun 2018 oleh Jacob Devlin beserta peneliti lainnya dari Google kemudian pada tahun 2019 dipublikasikan secara luas. Berikut merupakan contoh model BERT :



Gambar 2.7 Contoh Model BERT (Islek, I., & Oguducu, S. G. (2020))

Umumnya untuk melakukan *pre-trained* representasi bahasa terdiri dari dua cara yaitu berbasis *feature* dan fine-tuning (Devlin, J., et al., 2019) Pada kedua cara tersebut terdapat kelemahan seperti hanya mengenalkan tugas spesifik yang minim parameter dan dilatih pada tugas - tugas tahap akhir dengan sederhana menggunakan fine-tuning pada parameter yang telah dilatih. Dengan kelemahan seperti itu akan membatasi kemampuan dari representasi pre-trained khususnya pada pendekatan fine-tuning, selain itu batasan utamanya adalah pada model bahasa standar hanya berjalan secara searah dan terbatasnya pada pilihan arsitektur selama pre-training, sehingga dari hal itu diciptakanlah BERT dengan cara pendekatan berdasarkan fine-tuning, BERT menggunakan *masked language model* serta *next sentence prediction* yang kemudian berhasil menjadikan BERT sebagai *state-of-art* pada bidang NLP.

Arsitektur BERT terdiri dari multi-layer bidirectional Transformer encoder yang berdasarkan dari penelitian Transformer oleh Vaswani., et al (2017). BERT menggunakan Transformers yang tersusun oleh *bidirectional self-attention*. Terdapat dua ukuran model BERT yaitu BERT Base yang terdiri dari 12 layers (transformer blocks), 12 attention heads, dan 110 juta parameters dan BERT Large yang terdiri dari 24 layers (transformer blocks), 16 attention heads dan 340 juta parameters.

Terdapat dua langkah cara dalam menggunakan BERT yaitu pre-training dan fine-tuning. Pada saat proses pre-training model BERT melakukan pelatihan pada data yang belum dilabeli yang bertujuan untuk menyelesaikan berbagai tugas pre-training yang berbeda. Sedangkan untuk proses fine-tuning, model BERT menggunakan inisialisasi dengan parameter yang sebelumnya sudah dilatih dan semua parameter yang telah di fine-tuned menggunakan label data yang berasal dari permasalahan dari tugas yang ingin diselesaikan, masing-masing dari permasalahan

tugas (downstream task) terpisah sesuai model fine-tuned-nya, meskipun mereka menggunakan inisialisasi parameter yang sama.

Secara spesifik pada strategi fine-tuning terdapat dua strategi untuk menggunakan BERT yaitu *masked language model* merupakan model yang bertugas dalam memprediksi kata yang semestinya terdapat pada kalimat, dan strategi selanjutnya adalah *Next sentence prediction* ialah model pre-training yang bisa memprediksi kalimat lanjutan dari sebuah kalimat.

2.6 Pre training

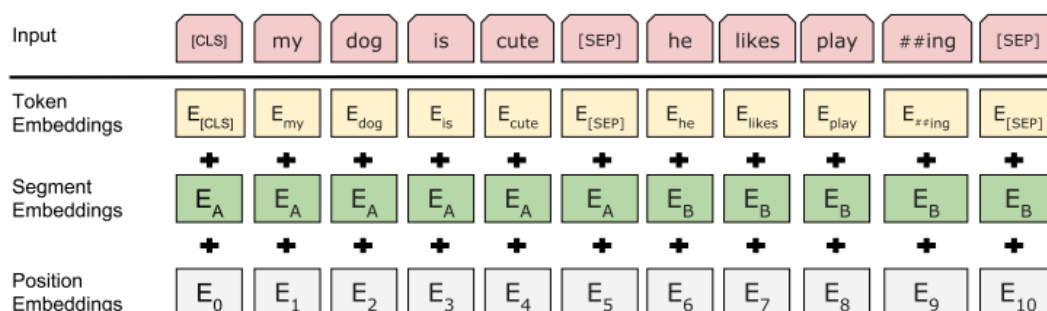
Pre training merupakan salah satu bagian proses penting yang terdapat pada BERT. Pre-trained model merupakan model yang telah latih oleh orang lain yang nantinya akan digunakan kembali pada penelitian lain sehingga akan memudahkan proses penelitian serta membantu pada tugas model dengan tujuan tertentu. Pada BERT terdapat dua proses yang terdapat pada pre-trained yaitu *Masked Language Model* dan *Next Sentence Prediction* (Devlin, J et al., 2019).

2.6.1 Masked Language Model

Masked Language Model adalah proses yang melakukan masking pada 15% kata yang masuk, secara acak sebagian besar dari 15% dari kata yang masuk diganti dengan [MASK] token. Proses tersebut secara keseluruhan pada bagian encoder BERT kemudian dari sebagian besar kata yang ditutupi dengan token tersebut akan diprediksi oleh model. Prediksi token tersebut kemudian dimasukan ke keluaran softmax dengan vocabulary yang ada pada masukan untuk kemudian mendapatkan keluaran akhir (Devlin, J et al., 2019). Alasan tidak seluruh kata diubah dengan token [MASK] adalah untuk menghindari permasalahan ketidakcocokan antara proses pre-training dan fine tuning karena token [MASK] tidak muncul selama fine-tuning. Dari 15% token hanya 80% kata yang diganti dengan token [MASK], 10% token diganti dengan token acak dan 10% token sisanya tidak diganti artinya pada sisa token ini merupakan kata yang sebenarnya.

2.6.1 Next Sentence Prediction

Next Sentence Prediction merupakan Proses yang bertujuan untuk memahami hubungan antar kalimat, Selama pelatihan model mendapatkan masukan pasangan kalimat dan model tersebut mempelajari dan memprediksi apakah kalimat kedua adalah kalimat lanjutan dari kalimat aslinya.



2.7 Fine Tuning

2.8 Normalized Discounted Cumulative Gain

NDCG (Normalized Discounted Cumulative Gain) merupakan metode metrik yang digunakan untuk memperhitungkan kualitas dari perankingan suatu data seperti pada perankingan hasil sistem rekomendasi. Sebelum menjelaskan lebih lanjut mengenai NDCG perlu penulis deskripsikan terlebih dahulu dari Gain, Cumulative Gain dan Discounted Cumulative Gain. Gain pada konteks NDCG merupakan score seberapa relevannya setiap item yang direkomendasikan sedangkan Cumulative Gain adalah jumlah nilai gain pada item K dari item K pertama yang direkomendasikan. Berikut bentuk formula Cumulative Gain :

$$CG_{@K} = \sum_{i=1}^K G_i \dots \dots \dots (2.26)$$

Discounted Cumulative Gain (DCG) merupakan jumlah bobot dari tingkat relevansi item - item yang diperingkat (Wang, Y., et al 2013). Bobot yang terdapat pada DCG merupakan fungsi penurunan dari posisi objek, karena hal tersebut diberi nama discount. Alasan utama dari *discount* tersebut adalah probabilitas pengguna melihat item tersebut akan menurun sehubungan dengan posisi peringkat item tersebut. jadi item pada rekomendasi teratas memiliki bobot item lebih besar di sisi lain rekomendasi yang berada di tingkat bawah mendapatkan bobot lebih rendah. Berikut bentuk formula Discounted Cumulative Gain :

$$DCG_{@K} = \sum_{i=1}^K \frac{G_i}{\log_2(i+1)} \dots \dots \dots (2.27)$$

NDCG seperti namanya merupakan bentuk DCG yang telah dinormalisasikan pada penyebutnya. Dengan menggunakan NDCG terdapat dua kelebihan dibandingkan metrik lainnya yaitu pertama, NDCG memungkinkan setiap dokumen yang diambil memiliki relevansi berjenjang dibandingkan metrik pengukuran tradisional lainnya yang hanya memungkinkan relevansi biner. Dengan kelebihan tersebut berarti dokumen dipandang secara relevan atau tidak relevan berdasarkan pengukuran perankingan sebelumnya sementara dengan NDCG terdapat derajat relevansi pada dokumen. Kedua, pada NDCG terdapat fungsi diskon atas peringkat yang mana pada metode metrik lainnya pembobotan dilakukan secara seragam pada semua posisi. Berikut merupakan formula NDCG :

$$nDCG_{@K} = \frac{DCG_{@K}}{IDCG_{@K}} \dots \dots \dots (2.28)$$

$$IDCG_{@K} = \sum_{i=1}^{K_{ideal}} \frac{2^{G_i-1}}{\log_2(i+1)} \dots \dots \dots (2.29)$$

Keterangan :

G : Gradien

K : Posisi rank item

I : posisi indeks G

2.9 Root Mean Square Error

2.10 Studi Pustaka (*State of the Art*)

Penelitian ini dilakukan karena...

No	Penulis	Metode	Dataset	Hasil
1	Billah, M et al. (2021)	Collaborative Filtering, PCA dan K-Means	Film Anime dataset	kompleksitas waktu sebesar 2.999602 dengan menggunakan akurasi nilai MMR dengan rata-rata sebesar 0.5619
2	Vie, J. J et al. (2018)	CNN, IllustrationN2Vec, ALS ² , LASSO ³ serta Steins gate.	Mangaki dataset	Evaluasi menggunakan RMSE sebesar 1.14954 ± 0.004
3	Nuurshadieq, & Wibowo, A. T. (2020).	Long short-term Memory	MyAnimeList dataset	Evaluasi menggunakan RMSE 1.4475
4	Juarto, B., & Suganda Girsang, A. (2021).	Neural Collaborative dan Sentence BERT	Microsoft news dataset	Ratio@10 sebesar 74% pada epoch 50, serta Accuracy 95.83%, Precision 92.69%, Recall 98.61%, F1 95.56% dan ROC 98%
5	Wang, W., et al. (2020).	LSTM dan CNN	MovieLens dataset	Menghasilkan MSE sebesar 0,876 DAN MAE 0,751
6	Khezrian, N et al. (2020).	Bidirectional Encoder Representations from Transformers (BERT)	freecode datasets	F1-Score@10 sebesar 46.5, Precision@5 TagBERT 41.83, Precision@10 sebesar 40.25 dan recall@10 sebesar 64.42
7	Wu, F et al. (2018)	LSTM dan Self Attention	Microsoft News Dataset (MIND)	Menghasilkan AUC sebesar 66.91, MRR sebesar 32.48,

				nDCG@5 sebesar 35.12 dan nDCG@10 sebesar 40.85
8	Wang, H., Lou, N., & Chao, Z. (2020)	LSTM dan CNN	MovieLens dataset	MSE dan MAE dari LSTM-CNN adalah 0.7724 dan 0.691739 masing - masing untuk MSE dan MAE serta dengan running time sebesar 64.2548.
9	Wang, T., & Fu, Y. (2020)	BiLSTM dan BERT	e-commerce dataset	Hasil terbaik menggunakan BERT Prec@1 0.555, Prec@10 0.079, Recall@10 0.791 dan NDCG@10 0.669
10	Kaviani, M., & Rahmani, H. (2020).	BERT	Twitter dataset	Menghasilkan Precision 15.18%, Recall 46.12% dan F_measure 22.34%
11	Pratiwi, R. W et al. (2020)	Attention-Based BiLSTM	Twitter dataset	Accuracy 79.68%, Precision 78.37%, Recall 79.26% dan F1 Score 78%
12	Zhuang, Y., & Kim, J. (2021).	BERT	TripAdvisor dataset	Rekomendasi Multi-criteria menunjukkan hasil evaluasi sebagai berikut HR@5 sebesar 0.333, HR@10 sebesar 0.25, HR@15 sebesar 0.217, NDCG@5 sebesar 0.694, NDCG@10 sebesar 0.606, NDCG@15 sebesar 0.569
13	Xu, C et al. (2021)	LSTM dan self-attention	Gowalla, ML-10M dan Foursquare dataset	Dengan evaluasi metrics Hit Ratio, NDCG dan MAP menghasilkan hasil evaluasi yang lebih baik disbanding penelitian lainnya.
14	Lund, J & Ng,	Autoencoder	MovieLens	Menghasilkan evaluasi

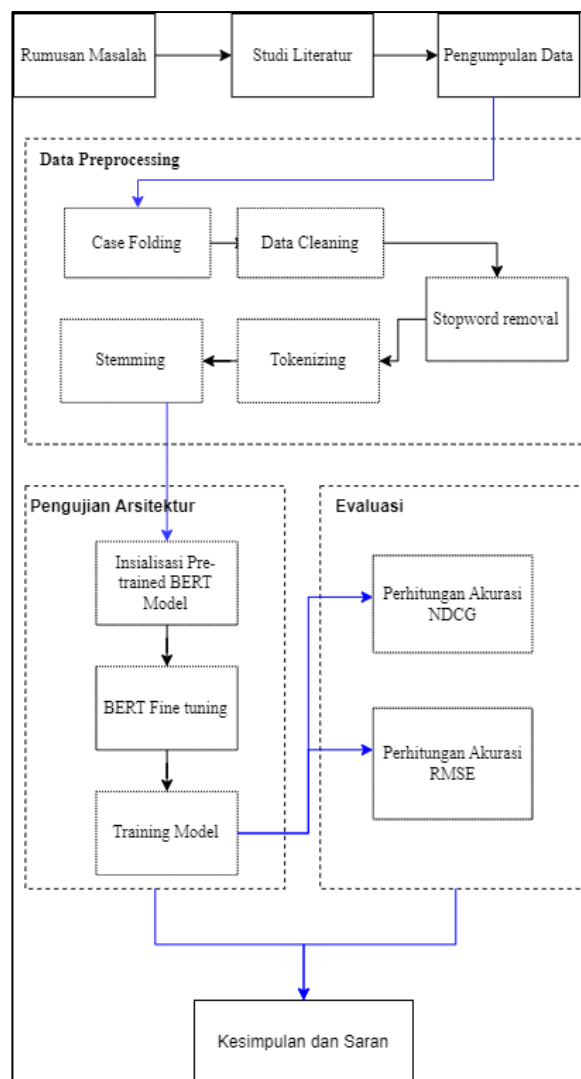
	Yiu-Kai. (2018).		dataset	yang lebih baik dibanding dengan KNN, hasil evaluasi dengan RMSE mendapat nilai sebesar 0.42
15	Rosa, R. L, et al (2019)	CNN, Bi-LSTM-RNN menggunakan SoftMax	Online Social Network datasets (facebook)	Menghasilkan accuracy sebesar 0.89 dan 0.90 dalam mendeteksi emosi depresi dan stress user, selain itu hasil dari rekomendasi sistem mencapai 94% user yang sangat puas, dibandingkan dengan sistem rekomendasi yang tidak menggunakan sentimen analysis yang hanya mencapai tingkat kepuasan 69%
16	Zhang, X., et al (2019)	Movie4Vec dan Bert4Movie	Hulu movies Series dataset	Menunjukkan hasil leaderboard sebesar 0.64754, hal ini menunjukkan performa melampaui benchmark.
17	Islek, I., & Oguducu, S. G. (2020).	BERT, GRU4REC, dan SASREC	Amazon dataset	Menunjukkan peningkatan yang cukup bagus dengan menggunakan BERT embedding sebesar 0.288 dan 0.3298 masing-masing untuk SASREC dan GRU4REC

Berdasarkan beberapa penelitian yang telah penulis telusuri sebelumnya terdapat beberapa metode yang merupakan metode yang terbaik yang bisa diterapkan serta objek yang bisa penulis teliti di penelitian ini yaitu Penelitian ini akan membandingkan dua metode yaitu metode BERT dan BiLSTM dengan attention dengan menggunakan dataset myanimelist.

BAB III Metodologi Penelitian

3.1 Metodologi Penelitian

Pada bagian ini akan dibahas tentang metodologi penelitian yang berisi tahapan - tahapan yang akan diterapkan pada penelitian ini. Dengan kerangka seperti ini tahapan penelitian akan lebih mudah dipahami dan diikuti oleh pihak yang tertarik akan penelitian ini. Tahapan Penelitian ini bisa di lihat pada gambar 3.1 di bawah :



Gambar 3.1 Tahapan Penelitian

3.2 Studi Literatur

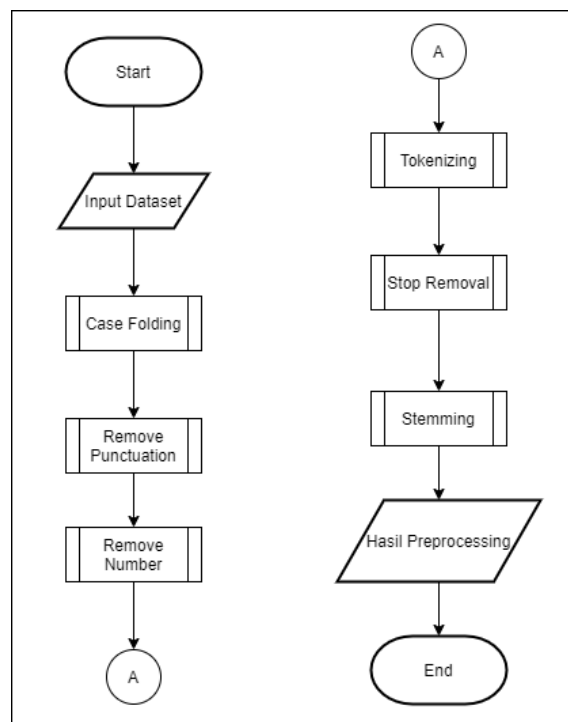
Studi Literatur merupakan suatu tahapan atau kegiatan yang melakukan pengumpulan data yang bertujuan untuk mendapatkan informasi penting yang berhubungan dengan masalah penelitian, metode serta berbagai sumber tulisan dari penelitian - penelitian sebelumnya. Sumber pengumpulan data pada studi literatur harus dari sumber yang bisa dipercaya seperti buku, artikel, jurnal dan lain sebagainya. Studi literatur pada penelitian ini bertujuan untuk mencari berbagai informasi yang berkaitan dengan penelitian sistem rekomendasi serta hal yang relevan dengannya.

3.3 Pengumpulan Data

Pengumpulan data adalah tahapan yang diterapkan untuk mendapatkan berbagai informasi yang akan digunakan pada penelitian ini. Data yang akan digunakan pada penelitian ini merupakan data sekunder yang berasal dari website MyAnimeList, data tersebut didapatkan secara tidak langsung atau sudah ada pihak ketiga yang sudah mengumpulkan. Data MyAnimelist sudah tersedia di Kaggle, terdapat beberapa dataset yang telah dikumpulkan oleh pihak ketiga yang cukup lengkap dengan update terakhir pada tahun 2019. Dataset tersebut bisa didapatkan dengan dua cara yaitu *Web Scrapping* atau melalui API. Sebelum bisa digunakan dataset tersebut perlu dilakukan proses *cleaning* dan *tokenizing* sehingga memudahkan dalam pengolahan model nantinya.

3.4 Pre-processing

Preprocessing merupakan tahapan yang perlu dilakukan untuk mempermudah model dalam melakukan memproses data, tahapan praprocessing juga dilakukan untuk memastikan data merupakan data yang berkualitas sehingga bisa membantu meningkatkan keakuratan model dan efisien termasuk mengurangi kemungkinan kesalahan yang akan terjadi pada model yang akan dibuat. Pada tahapan *praprocessing* ini terdiri dari tahapan *case folding*, *remove punction*, *remove number*, *tokenizing*, *stop removal*, *stemming*. Flowchart proses *preprocessing* dapat dilihat pada gambar 3.2 berikut :



Gambar 3.2 Flowchart preprocessing

3.4.1 Case Folding

3.4.2 Remove Punctuation

3.4.3 Remove Number

3.4.4 Stopword Removal

3.4.5 Tokenizing

3.4.6 Stemming

3.5 Pembuatan Model

3.5.1 BERT

3.6 Pengujian Sistem

3.7 Metodologi Pengembangan Sistem

3.7.1 Analisis Kebutuhan Sistem

3.7.2 Kebutuhan Fungsional

3.7.3 Kebutuhan Non-Fungsional

3.7.4 Proses Desain

3.7.5 Perancangan Sistem

3.7.8 Perancangan Pengujian

Daftar Pustaka

Ricci, F., Rokach, L., Shapira, B., & Kantor, P. B.,. (2011). Recommender Systems Handbook. In Recommender Systems Handbook.

Cheng, H. T., Koc, L., Harmsen, J., Shaked, T., Chandra, T., Aradhye, H., Anderson, G., Corrado, G., Chai, W., Ispir, M., Anil, R., Haque, Z., Hong, L., Jain, V., Liu, X., & Shah, H. (2016). Wide & deep learning for recommender systems. *ACM International Conference Proceeding Series*, 15-Septemb, 7–10.

Burke, R., Felfernig, A., & Göker, M. H. (2011). Recommender Systems: An Overview. *AI Magazine*, 32(3), 13.

Isinkaye, F. O., Folajimi, Y. O., & Ojokoh, B. A. (2015). Recommendation systems: Principles, methods and evaluation. *Egyptian Informatics Journal*, 16(3), 261–273.

Modallal, S. (n.d.). Survey on Collaborative Filtering , Content-based Filtering and Hybrid Recommendation System Filtering and Hybrid Recommendation System (Modallal, S ., 2011).

Burke, R. (2007). Hybrid web recommender systems. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 4321 LNCS, 377–408.

Suyanto., Nur Ramadhan, Kurniawan., Mandala, Satria., (2019) Penerbit Informatika

Alfarhood, M., & Cheng, J. (2021). Deep learning-based recommender systems. *Advances in Intelligent Systems and Computing*, 1232(1), 1–23.

Ng, Andrew. (n.d.). Structuring Machine Learning Projects [MOOC]. Coursera.

Batmaz, Z., Yurekli, A., Bilge, A., & Kaleli, C. (2019). A review on deep learning for recommender systems: challenges and remedies. *Artificial Intelligence Review*, 52(1).

Battaglia, P. W., Hamrick, J. B., Bapst, V., Sanchez-Gonzalez, A., Zambaldi, V., Malinowski, M., Tacchetti, A., Raposo, D., Santoro, A., Faulkner, R., Gulcehre, C., Song, F., Ballard, A., Gilmer, J., Dahl, G., Vaswani, A., Allen, K., Nash, C., Langston, V., ... Pascanu, R. (2018). Relational inductive biases, deep learning, and graph networks. 1–40.

Sherstinsky, A. (2020). Fundamentals of Recurrent Neural Network (RNN) and Long Short-Term Memory (LSTM) network. *Physica D: Nonlinear Phenomena*, 404(March), 1–43.

Goodfellow, Ian., Bengio, Yoshua., Courville, Aaron., (2016). Deep Learning. *Nature*, 26(7553), 436

Gao, Z., & Wang, X. (2019). Deep learning. *EEG Signal Processing and Feature Extraction*, 325–333.

Lops, P., Gemmis, M. De, & Semeraro, G. (2011). *Recommender Systems Handbook*. In *Recommender Systems Handbook* (Issue January).

Nuurshadieq, & Wibowo, A. T. (2020). Leveraging Side Information to Anime Recommender System using Deep learning. *2020 3rd International Seminar on Research of Information Technology and Intelligent Systems, ISRITI 2020*, 62–67.

Jindal, R., & Jain, K. (2019). A review on recommendation systems using deep learning. *International Journal of Scientific and Technology Research*, 8(10), 2978–2985.

Jan Wira Gotama Putra, et al. (2020). Pengenalan konsep pembelajaran mesin dan deep learning. *Computational Linguistics and Natural Language Processing Laboratory*, 4, 1–235.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 2017-Decem(Nips), 5999–6009.

Xu, C., Feng, J., Zhao, P., Zhuang, F., Wang, D., Liu, Y., & S. Sheng, V. (2021). Long- and short-term self-attention network for sequential recommendation. *Neurocomputing*, 423, 580–589.

Huang, R., McIntyre, S., Song, M., Haihong, E., & Ou, Z. (2018). An attention-based recommender system to predict contextual intent based on choice histories across and within sessions. *Applied Sciences (Switzerland)*, 8(12).

Katrompas, A., & Metsis, V. (2022). Enhancing LSTM Models with Self-attention and Stateful Training. *Lecture Notes in Networks and Systems*, 294, 217–235.

Zhang, S., Tay, Y., Yao, L., & Sun, A. (2018). Next Item Recommendation with Self-Attention. *August*.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL HLT 2019 - 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies - Proceedings of the Conference*, 1(Mlm), 4171–4186.

Kaviani, M., & Rahmani, H. (2020). EmHash: 基于 BERT 嵌入的神经网络 Hashtag 推荐. *2020 6th International Conference on Web Research, ICWR 2020*, 113–118.

Pratiwi, R. W., Sari, Y., & Suyanto, Y. (2020). Attention-Based BiLSTM for Negation Handling in Sentimen Analysis. *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, 14(4), 397.

Zhuang, Y., & Kim, J. (2021). A bert-based multi-criteria recommender system for hotel promotion management.

Lund, J & Ng, Yiu-Kai. (2018). Movie Recommendations Using the Deep Learning Approach.

Rosa, R. L., Schwartz, G. M., Ruggiero, W. V., & Rodriguez, D. Z. (2019). A Knowledge-Based Recommendation System That Includes Sentiment Analysis and Deep Learning. *IEEE Transactions on Industrial Informatics*, 15(4), 2124–2135.

Zhang, X., Yuan, X., Li, Y., & Zhang, Y. (2019). Cold-start representation learning: A recommendation approach with BeRt4Movie and Movie2vec. *MM 2019 - Proceedings of the 27th ACM International Conference on Multimedia*, 2612–2616.

Wang, Y., Wang, L., Li, Y., He, D., Chen, W., & Liu, T. Y. (2013). A theoretical analysis of NDCG ranking measures. *Journal of Machine Learning Research*, 30, 25–54.

Soni, B., Thakuria, D., Nath, N., Das, N., & Boro, B. (2021). RikoNet: A Novel Anime Recommendation Engine.

Islek, I., & Oguducu, S. G. (2020). A Hybrid Recommendation System Based on Bidirectional Encoder Representations. *Communications in Computer and Information Science*, 1323, 225–236.

Cordonnier, J.-B., Loukas, A., & Jaggi, M. (2019). On the Relationship between Self-Attention and Convolutional Layers.

Lampiran